



# 02.1-DeepLearning-General Guidance

## 1. Framework of ML

### 1.1 訓練資料與測試資料

### 1.2 訓練的過程

## 2. General Guide

### 2.1 訓練資料上的 Loss

#### 2.1.1 Model Bias

#### 2.1.2 Optimization

#### 2.1.3 如何區分兩種情況？

### 2.2 測試資料上的 Loss

#### 2.2.1 Overfitting

### 2.3 不要加過大的彈性 $\Rightarrow$ Model bias

### 2.4 Bias-Complexity Trade-off

### 2.5 Cross Validation

### 2.6 N-fold Cross Validation

### 2.7 Mismatch

## 1. Framework of ML

### 1.1 訓練資料與測試資料


Training data:  $\{(x^1, \hat{y}^1), (x^2, \hat{y}^2), \dots, (x^N, \hat{y}^N)\}$

Testing data:  $\{x^{N+1}, x^{N+2}, \dots, x^{N+M}\}$

### 1.2 訓練的過程

Training data:  $\{(x^1, \hat{y}^1), (x^2, \hat{y}^2), \dots, (x^N, \hat{y}^N)\}$

Training:



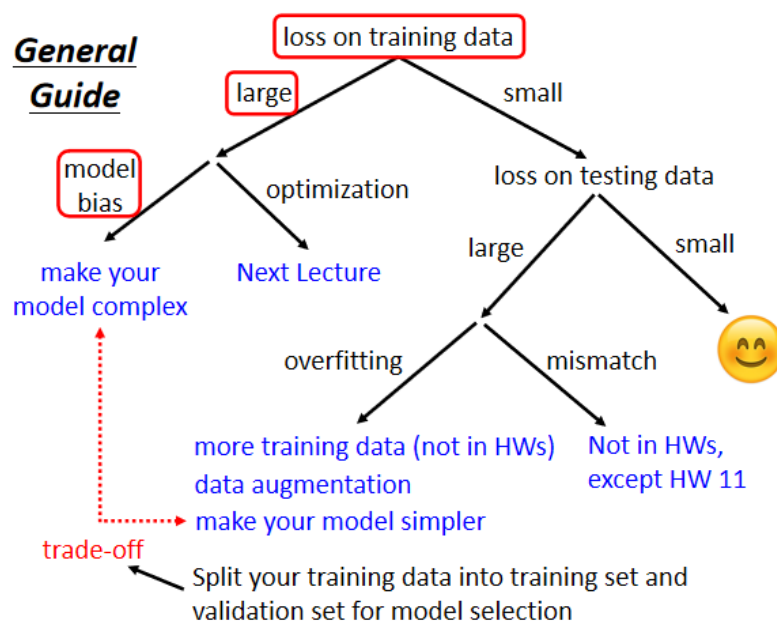
Testing data:  $\{x^{N+1}, x^{N+2}, \dots, x^{N+M}\}$

Use  $y = f_{\theta^*}(x)$  to label the testing data

$\{y^{N+1}, y^{N+2}, \dots, y^{N+M}\} \rightarrow$  Upload to Kaggle


1. 寫出一個有未知參數的 function，參數用  $\theta$  來表示
2. 確定損失函數，判斷 function 的參數  $\theta$  好不好
3. optimization，得到使損失函數最小的參數  $\theta^*$

## 2. General Guide



### 2.1 訓練資料上的 Loss

#### 2.1.1 Model Bias




所有的 function 集合起來得到一個 function 的 set。但是這個 function 的 set 太小了，沒有包含任何一個 function 可以讓 loss 變低  $\Rightarrow$  可以讓 loss 變低的 function 不在 model 可以描述的範圍內

解決方法：

重新設計一個 **Model**，一個更複雜的、更有彈性的、有未知參數的、需要更多 features 的 function

## 2.1.2 Optimization



可能會卡在 local minima（局部極小值/鞍點）的地方，沒有辦法找到真的可以讓 loss 很低的參數

## 2.1.3 如何區分兩種情況？

- Start from shallower networks (or other models), which are easier to train.

看到一個從來沒有做過的問題，可以先跑一些比較小、比較淺的 network，或甚至用一些不是 deep learning 的方法  $\Rightarrow$  比較容易做 **optimize**，較不會有 **optimization** 失敗的問題

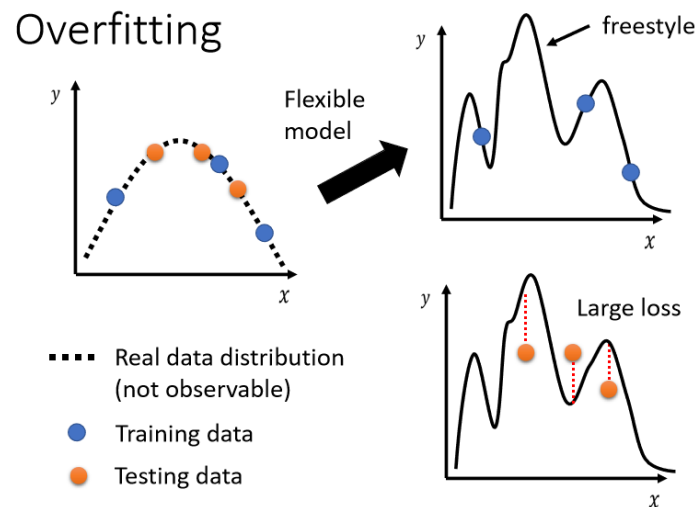
- If deeper networks do not obtain smaller loss on training data, then there is optimization issue.

如果發現深的 model 跟淺的 model 比起來，深的 model 明明彈性比較大，但 loss 卻沒有辦法比淺的 model 壓得更低，那就代表 **optimization** 有問題

## 2.2 測試資料上的 Loss

## 2.2.1 Overfitting

training 的 loss 小，testing 的 loss 大，有可能是 **overfitting**。如果你的 model 它的自由度很大的話，它會產生非常奇怪的曲線，導致訓練集上的結果好，但是測試集上的 loss 很大



解決：

1. 增加訓練集

雖然你的 model 它的彈性可能很大，但是因為數據樣本非常非常的多，它就可以限制住

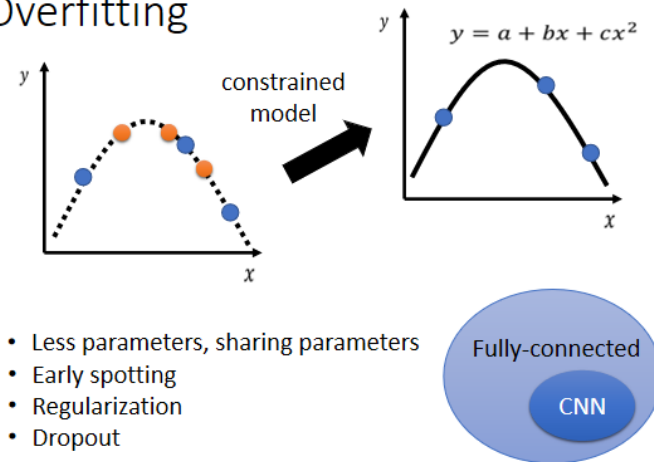
**Data Augmentation**：用一些對於問題的理解，從已有的數據中創造出新的數據（注意合理性）

**Data augmentation** (you can do that in HWs)



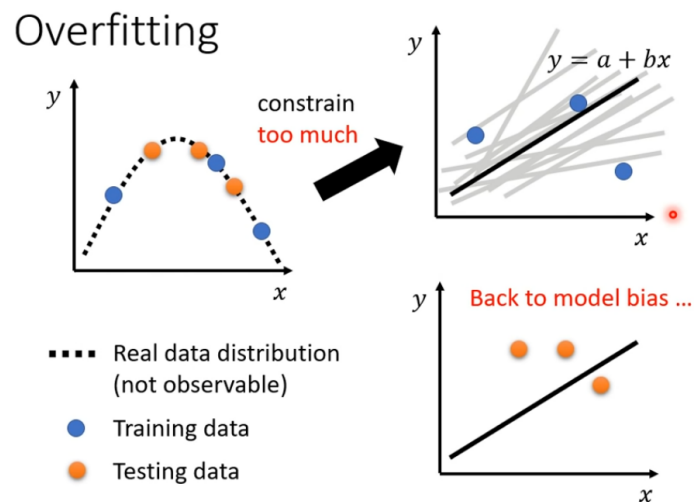
2. 限制模型，使之不要有那麼大的彈性

## Overfitting




- 給比較少的參數（比如神經元的數目）；模型共用參數 (03-CNN)
- 使用比較少的 features
- Early Stopping
- Regularization
- Dropout

## 2.3 不要加過大的彈性 $\Rightarrow$ Model bias



## 2.4 Bias-Complexity Trade-off

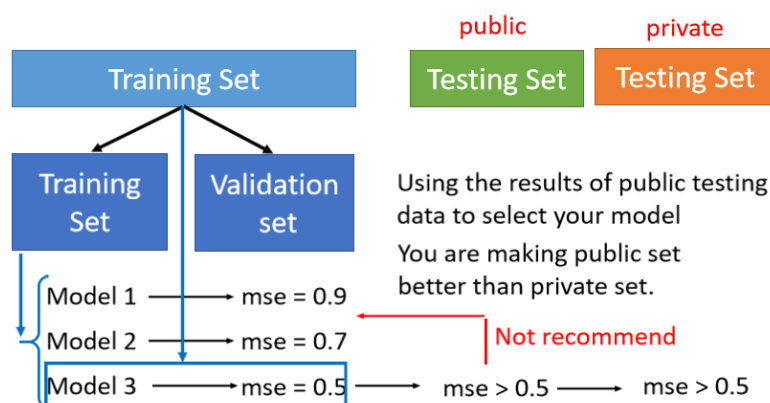
## Bias-Complexity Trade-off



所謂比較複雜，是它可以包含的 **function** 比較多，它的參數比較多，這個就是一個比較複雜的 **model**

隨著 model 越來越複雜，**training** 的 **loss** 可以越來越低，當 model 越來越複雜的時候，剛開始 **testing** 的 **loss** 會跟著下降；但是當複雜的程度超過某一個程度以後，**testing** 的 **loss** 就突然暴增

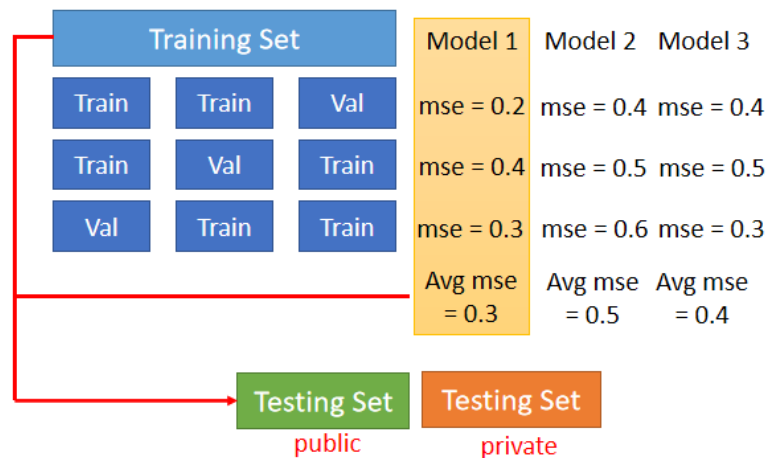
## 2.5 Cross Validation



1. 把 training 的資料分成兩部分，一部分叫作 training set，一部分是 validation set
2. 在 validation set 上面去衡量它們的分數，根據 validation set 上面的分數去挑選結果，不要管在 public testing set 上的結果以避免 overfitting

## 2.6 N-fold Cross Validation

**N-fold Cross Validation** 就是先把訓練集切成 N 等份，切完以後拿其中一份當作 Validation Set，另外 N-1 份當 training set，重覆 N 次



把多個模型在這三個 setting 下通通跑過一次，把 N 種狀況的結果都平均起來，看看誰的結果最好；最後再把選出來的 model（這裡是 Model 1），再拿全部的 training set（public）訓練 Model 1，訓練完畢後，再用在 testing set（private）上面

## 2.7 Mismatch

訓練集跟測試集的分佈是不一樣的，依照對數據本身的理解來判斷

- Your training and testing data have different distributions. Be aware of how data is generated.

***Most HWs do not have this problem, except HW11***

### Training Data



Simply increasing the training data will not help.

### Testing Data

